데이터의 양·품질·행동 차원을 바꾸며 무엇을 확인했는가

Agibot Toy2Box 모방학습 팀프로젝트

연구의 출발 가정은 **"데이터의 품질과 구성이 좋아지면 학습 결과도 좋아질 것이다"**였다. 강의 자료의 데이터 품질·구성 연구 축을 바탕으로, **처음 20개부터 품질을 고려해** 손끝 회전 명령 두 성분을 제한하고 시범 동작의 일관성을 높이려 했다.

이 품질 중심 수집 전략을 유지하면서 먼저 데이터의 **양**을 97개로 늘렸다. 이어 영상과 지표에서 발견한 **문제 동작을 추가 개선**해 100개를 구성했다. 마지막에는 처음의 회전 제한 전략을 증강 데이터와 실제 학습하는 **행동 출력 차원**까지 일관되게 반영했다.

단계	바꾼 내용	사람 원본 / 성공 Mimic	평균 성공률
A · 품질 중심 수집	일관성을 높이려고 X·Z 회전 입력 제한	20 /500	40.5%
B · 양 확대	같은 수집 전략에서 시범 수 확대	97 /1,000	58.0%
C · 품질 개선	문제 동작 재수집 9개 + 새 배치 3개	100 /1,000	55.5%
D · 차원 축소	같은 100개로 회전 제약을 적용하고 5D 출력 학습	100 /1,000	71.0%

품질을 고려해 수집한 첫 20개의 해석

첫 20개에는 **조작 자유도를 줄여 일관된 시범을 모으려는 품질 개선 의도**가 이미 적용돼 있었다. 회전 명령 r_x·r_z를 사용하지 않고 수집한 이 데이터로 성공 Mimic 500개를 생성해 학습했으며, 101은 39%, 111은 42%, 평균은 **40.5%**를 얻었다.

이 수치는 **품질을 고려해 설계한 첫 데이터셋에서 얻은 정책 성능**이다. 정책 성공률에는 원본 수, 증강 과정, 학습 표현 등이 함께 영향을 주므로, 40.5%라는 결과만으로 원본 시범의 품질이 낮았다고 판단할 수 없다.

다음 질문은 **"이 수집 전략을 유지하면서 데이터의 양을 늘리면 더 좋아질까?"**였다. 같은 회전 제한을 유지해 97개로 확대했고, 이후 구체적으로 확인된 트럭 윗면 파지·복잡한 접근·상자 접촉을 추가 개선해 100개를 구성했다.

> **전체 흐름:** 품질을 고려한 20개에서 출발해, 같은 전략으로 양을 늘리고 문제 동작을 추가 개선했다. 마지막에는 수집 의도를 생성·학습·평가의 행동 차원에도 반영해 72%·70%, 평균 71%를 얻었다.

공통 평가: 학습 시드 101·111의 최종 모델을 각각 100회 평가, 평가 시드 42, horizon 800. 평균은 두 모델의 평균이며, 두 회전 명령의 정확한 의미는 다음 쪽에 설명한다.

처음부터 제한한 두 회전값은 무엇인가

환경에 입력하는 7개 명령은 `a = [Δx, Δy, Δz, r_x, r_y, r_z, g]`이다. 앞의 3개는 손끝 위치 변위(m), 다음 3개는 손끝의 **상대 회전벡터(rad)**, 마지막은 그리퍼 열기·닫기 명령이다. 제어기는 이 명령을 로봇 기준좌표계의 현재 손끝 자세에 적용해 관절 목표로 변환한다.

인덱스	값	의미·단위	수집에서의 사용
0	Δx	손끝 x 방향 위치 변위(m)	사용
1	Δy	손끝 y 방향 위치 변위(m)	사용
2	Δz	손끝 z 방향 위치 변위(m)	사용
3	r_x	X축 주위 회전 변위(rad) ·roll 계열	0 유지 ·Z/X 키 미사용
4	r_y	Y축 주위 회전 변위(rad) ·pitch 계열	사용 ·B/G 키
5	r_z	Z축 주위 회전 변위(rad) ·yaw 계열	0 유지 ·C/V 키 미사용
6	g	+1 열기 /−1 닫기	사용 ·K 키

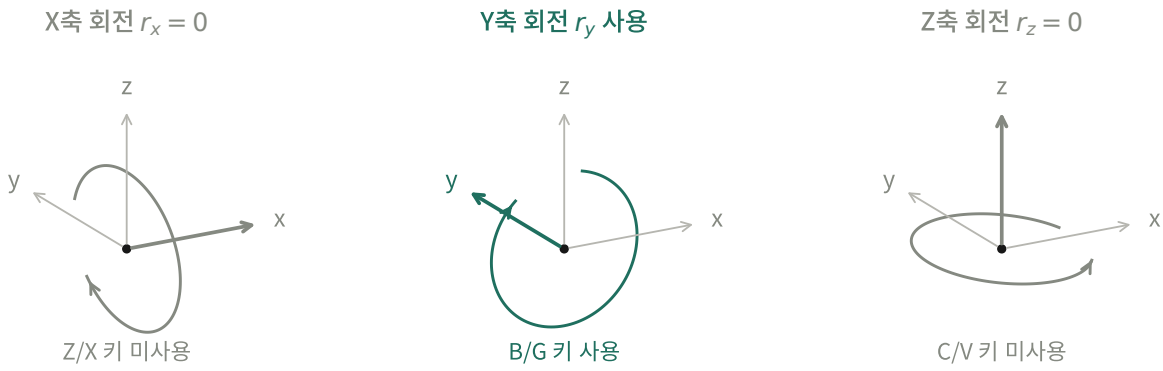


그림 1. 로봇 기준좌표계의 회전축 개념도. 원본의 사용 명령은 위치 3 개·회전 1 개·그리퍼 1개다. 축과 명령의 관계를 도식화했다.

예를 들어 `[r_x,r_y,r_z]=[0,0.05,0]`은 현재 자세에서 Y축 주위로 0.05 rad(약 2.86°)만큼 회전한 자세를 목표로 주는 명령이다. 일반적으로 회전벡터의 크기가 회전각, 정규화한 방향이 회전축이다. roll·pitch·yaw는 축을 설명하기 위한 명칭이고, 저장값을 독립적인 Euler각 3개나 손목 관절각 3개와 동일하게 해석하지 않는다.

> **r_x=r_z=0은 손목 관절 두 개를 고정했다는 뜻이 아니다.** 그 두 방향의 회전 변위 명령을 주지 않은 것이다. 접촉·제어 추종 오차 등으로 실제 손끝 자세가 달라질 수 있으므로 자세 관측은 유지했다.

확인 근거:Se3Keyboard.advance의 회전벡터 출력, RMPFlowAction._compute_frame_pose의 로봇 기준좌표계 변환, apply_delta_pose의 angle-axis 적용. 수집 원본 20·97·100개 모두 두 명령 성분이 정확히 0이었다.

1단계 비교 · 데이터 양을 늘리면 개선되는가

첫 20개부터 품질을 고려해 두 회전 명령을 제한했다. 다음에는 **같은 수집 전략을 유지하며 데이터 양을 늘렸을 때의 변화**를 확인하고자 80개를 추가 수집했다. 총 100개 중 기존 자동 grasp 검출·재생 기준을 통과한 97개를 사용했고, 기준 자체는 바꾸지 않았다.

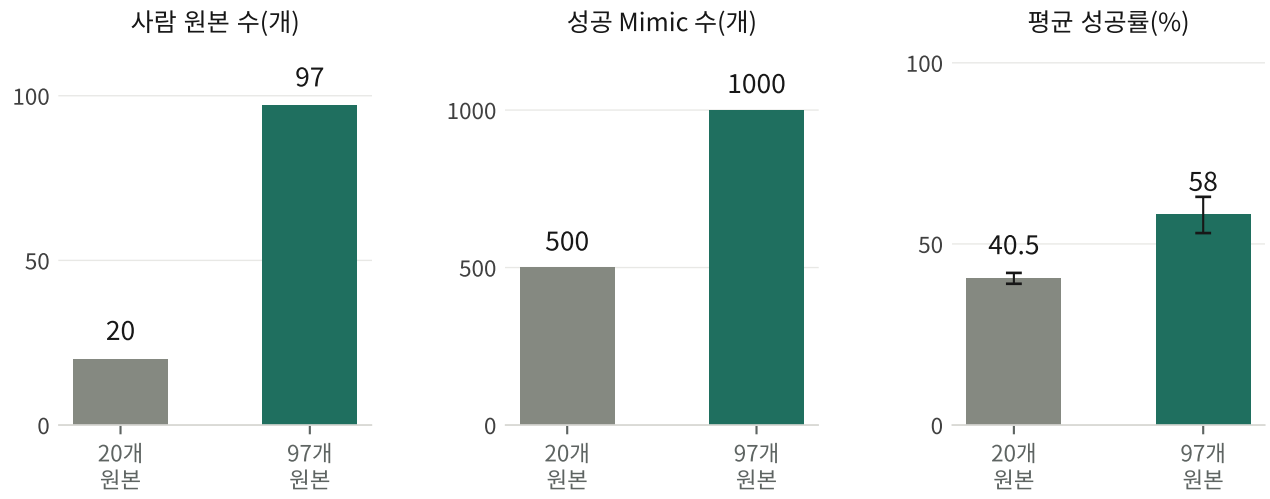


그림 2. 양 확대 전후의 데이터 수와 모델 성공률. 성공률 막대는 두 학습 시드 평균, 오차막대는 시드 간 표준편차(ddof=0, n=2)이며 신뢰구간이 아니다. 각 모델의 평가는 100회다.

지표	초기 20개(A)	양 확대 97개(B)
사람 시범의 제어 step	4,711	23,581
학습에 사용한 성공 Mimic	500 개·128,804 step	1,000 개·260,235 step
101 모델 성공률	39%	63%
111 모델 성공률	42%	53%
평균 성공률	40.5%	58.0%
두 시드 차이 /표준편차	3%p /1.5%p	10%p /5.0%p

> 평균 성공률은 **40.5→58.0%(+17.5%p)**로 상승했다. 데이터 양 확대 방향과 일치하는 관찰이지만, 두 모델의 차이는 3→10%p로 커졌다. “더 많이 모으기”만으로 결과의 일관성까지 확보되지는 않았다.

이 단계에서는 사람 원본 수 20→97과 성공 Mimic 수 500→1,000이 함께 증가했다. 따라서 관찰한 상승을 사람 시범 수 하나의 독립 효과라고 단정하지 않는다. BC-RNN은 각 원본에서 생성한 성공 Mimic 데이터로 학습했다.

2단계 비교 · 문제가 보인 원본 동작을 개선하다

97개 영상과 수치 지표를 함께 검토하며 트럭 위를 누르는 파지, 불필요하게 복잡한 접근, 상자를 건드리는 동작을 줄이는 것을 목표로 했다. 사용자의 영상 판단에 따라 95번은 유지하고 90번을 교체했다. 최종 재수집은 **11·24·52·65·66·75·85·89·90번** 9개였다.

같은 상황에서 동작을 바꾸기 위해 기존 시범의 초기 상태를 복원했다. 여기에 새 배치 3개를 더해 **기존 유지 88개 +재수집 9개 + 새 배치 3개 =100개**를 구성했다. 아래 지표는 같은 초기 배치에서 다시 수집한 9개의 전후를 비교한 것이다.

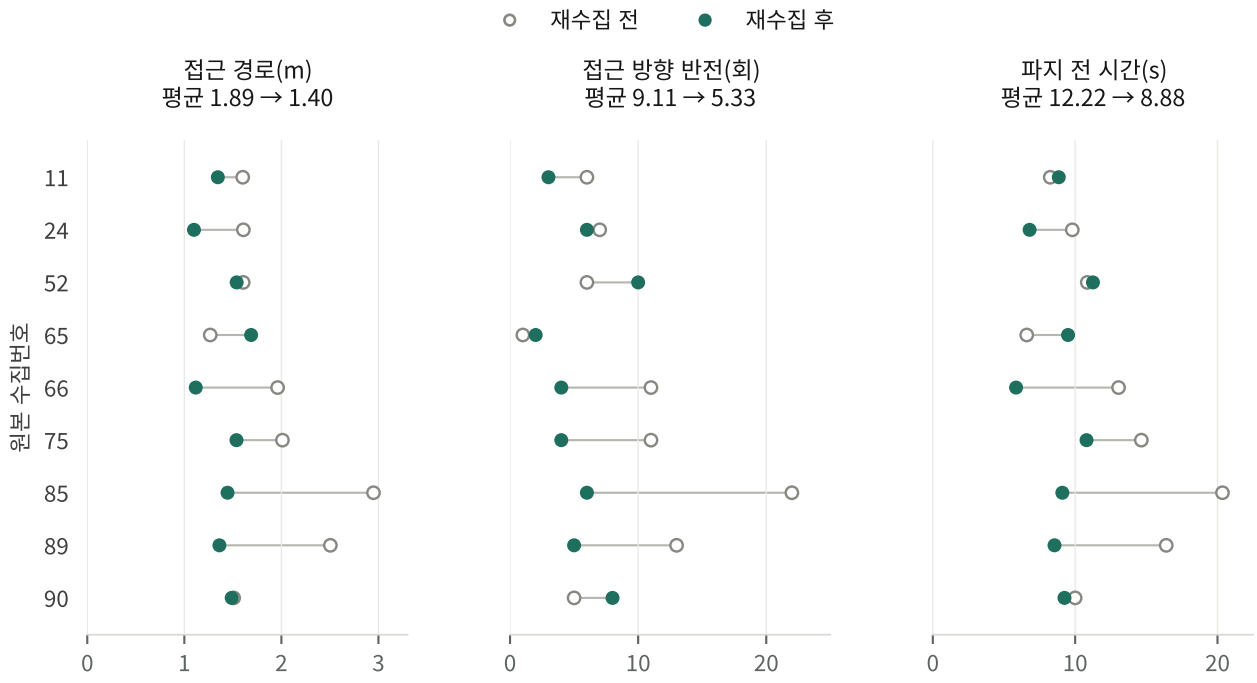


그림 3. 재수집 9개의 전후 비교. 각 행은 같은 수집번호의 한 쌍이며, 빈 원은 이전·채운 원은 이후다. 접근은 시작부터 최초 자동 grasp 신호까지로 정의했다. 방향 반전은 실제 속도가 아닌 병진 명령의 부호 전환이다.

9개 시범의 평균	재수집 전	재수집 후	감소한 시범
파지 전 손끝 경로(m)	1.89	1.40	8/9개
파지 전 방향 반전(회)	9.11	5.33	6/9개
파지까지 시간(s)	12.22	8.88	6/9개

일부 지표는 증가했다. 예를 들어 65번은 상자를 피했지만 접근 경로가 길어졌고, 52번은 파지 전 방향 반전이 늘었다. 따라서 재수집 전체를 모든 지표에서 개선됐다고 묶지 않았다. 경로를 짧게 만드는 것도 장애물 회피와 안정적인 파지보다 항상 우선하는 품질 기준은 아니다.

품질 지표는 개선됐지만, 평균 성능은 오르지 않았다

상자를 건드리는 동작은 초기 위치 대비 상자의 최대 XY 이동량으로 확인했다. 24번은 **6.15→0.14cm**, 65번은 **2.78→0.15cm**로 줄었다. 전체 원본에서 이동량 2cm를 넘은 시범도 97개 중 2개에서 재검수 100개 중 0개로 감소했다.

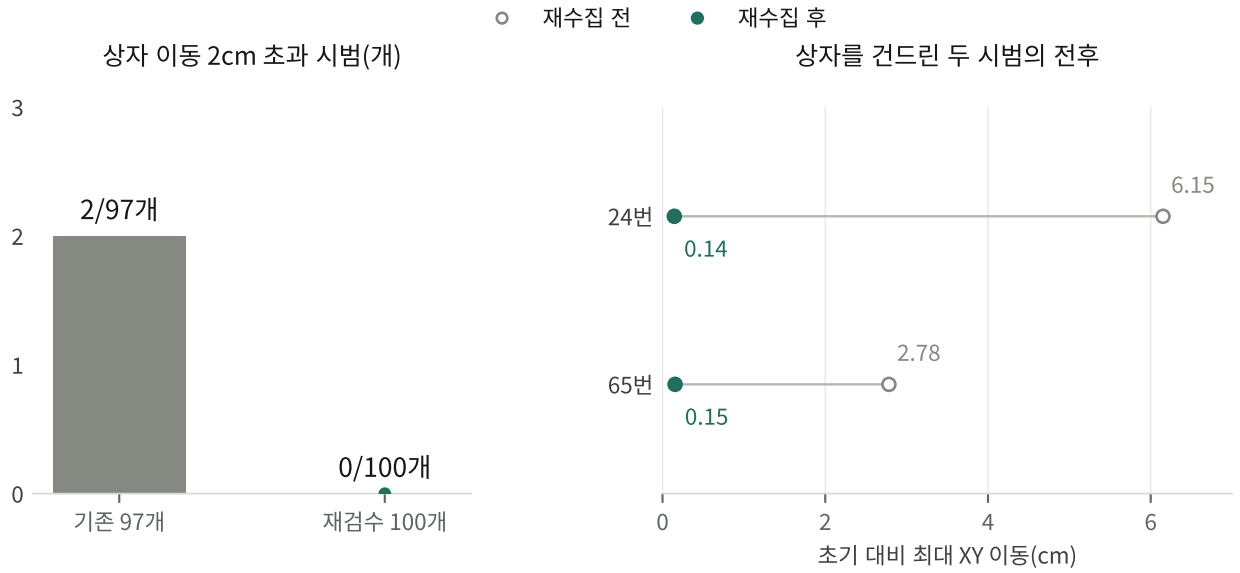


그림 4. 왼쪽은 각 원본 데이터 전체의 상자 이동 2cm 초과 시범 수, 오른쪽은 24·65번의 실제 최대 이동량이다.2cm는 분석용 기준이며 과제 성공 조건을 바꾼 값이 아니다. 상자 이동이 작다는 사실만으로 모든 접촉이 없었다고 판단하지 않는다.

정책 평가 지표	97개(B)	품질 개선 100개(C)	변화
101 모델 성공률	63%	58%	−5%p
111 모델 성공률	53%	53%	동일
평균 성공률	58.0%	55.5%	−2.5%p
두 시드 차이	10%p	5%p	절반으로 감소
시드 간 표준편차	5.0%p	2.5%p	절반으로 감소

> **품질 개선의 성능 효과는 제한적이었다.** 원본에서 확인한 접근·상자 이동 지표는 개선됐지만 모델 평균은 상승하지 않았다. 대신 이번 두 학습 시드의 관찰된 차이와 표준편차가 줄었다. 편차 감소와 평균 성능 개선은 구분해야 한다.

트럭 윗면의 손가락 끝 접촉은 기존 분석과 사용자 영상 판단을 바탕으로 재수집 목표에 반영했다. 재수집 후 동일한 60 Hz 접촉 검사를 새로 수행하지 않았으므로 “끝 접촉이 0건이 됐다”고 보고하지 않는다.

3단계 비교 · 사용하지 않는 두 성분을 학습에서 빼다

사람이 두 회전을 사용하지 않아도 기존 모델의 출력은 7차원이었다. Mimic은 원본 action을 그대로 복사하지 않고 물체 기준 손끝 목표를 새 배치로 변환한 뒤, 현재 자세와 목표의 차이를 명령으로 만들고 노이즈를 더한다. 그 결과 원본에서 0인 두 성분이 생성 데이터에서는 다시 0이 아닌 값으로 나타났다.

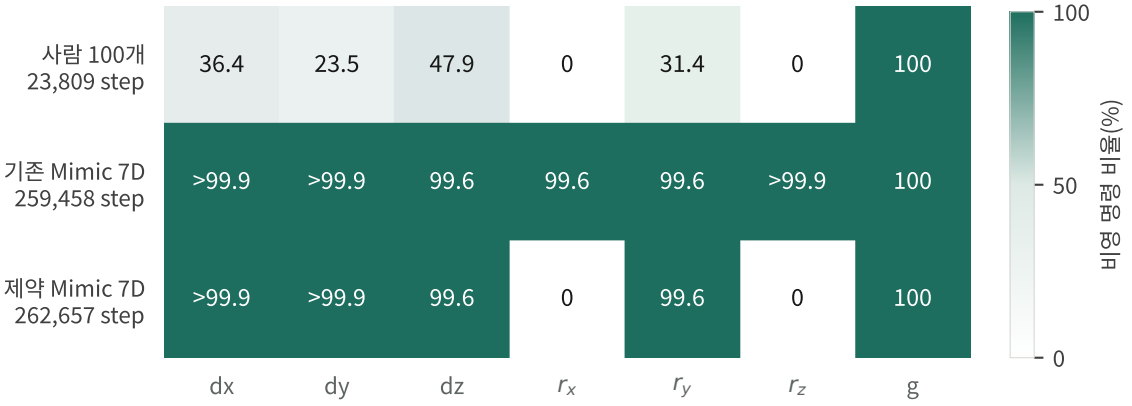


그림 5. 기록된 step 중 명령값이 0이 아닌 비율(|a|>10^{-6}). 행별 분모는 23,809·259,458·262,657 step이다. 비영 비율은 명령의 빈도이며 실제 회전 크기나 물리적 손목 회전 확률이 아니다. g는 항상±1이므로 100%다.

마지막 실험은 첫 20개부터 품질을 높이려고 적용한 회전 제한 전략을 실제 학습까지 연결했다. 같은 100개 원본을 유지하면서 **Mimic 실행 명령의 r_x·r_z를 0으로 제한해 성공 궤적 1,000개를 다시 만들고**, 학습 정답과 정책 출력에서 두 성분을 제거했다. 과거 7D 성공 궤적의 열만 지운 방식은 아니다.

구분	기존 100 개·7D(C)	차원 축소 실험(D)
사람 원본	r_x=r_z=0인 같은 100개	그대로 유지
학습 action	[Δx,Δy,Δz,r_x,r_y,r_z,g]	[Δx,Δy,Δz,r_y,g]
모델 출력	7개	5개
정책 관측	손끝·그리퍼·물체 상태 23개	23개 그대로
환경에 전달	7개 명령	[Δx,Δy,Δz,0,r_y,0,g]로 확장

> 초기에는 **7개 슬롯 중 5개만 사용하는 사람 데이터**를 모았다. 마지막에는 **모델이 실제로 5개만 출력하도록** 바꾸었다. 즉 단순한 0값 포함과 학습 출력 차원 축소는 서로 다른 단계다.

기존 환경과 성공·종료 조건은 유지했다. 생성 중 제거 축 0, 저장 action0, 체크포인트 출력 5개, 평가 명령의 5→7 확장을 확인했다. 자세 관측을 유지했으므로 실제 접촉이나 추종 오차를 없는 것으로 처리하지 않았다.

최종 결과 · 두 모델 모두 70%대에 도달했다

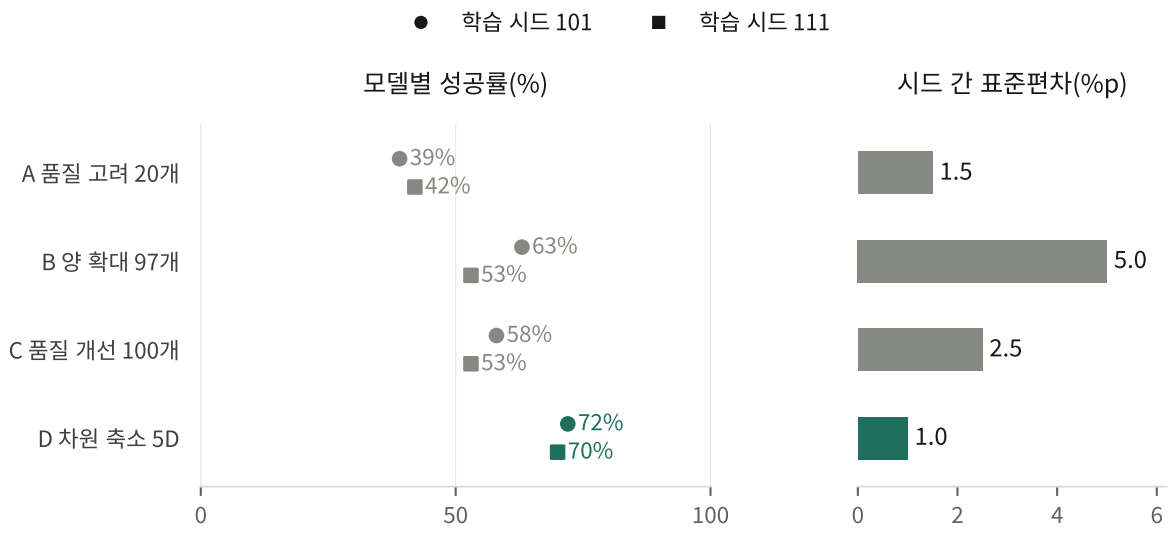


그림 6. 왼쪽은 각 모델의 100회 평가 결과를 모두 표시한 값이며 원은 101·사각형은 111이다. 오른쪽은 두 성공률의 표준편차(ddof=0, n=2)다. 이는 일반적인 학습 안정성의 신뢰구간이 아니라 이번 두 모델의 관찰된 퍼짐이다.

실험	101 성공/100회	111 성공/100회	평균	시드SD
A · 품질 고려 20개	39	42	40.5%	1.5%p
B · 양 확대 97개	63	53	58.0%	5.0%p
C · 품질 개선 100개	58	53	55.5%	2.5%p
D · 행동 차원 축소 5D	72	70	71.0%	1.0%p

같은 100개 원본을 쓰는 C와 D를 비교하면 101은 58→72%(+14%p), 111은 53→70%(+17%p)였다. 평균은 **55.5→71.0%(+15.5%p)**, 시드 간 표준편차는 2.5→1.0%p로 바뀌었다. 전체 평가로는 142/200회 성공이다.

> **품질을 고려한 초기 수집 → 같은 전략에서 양 확대 → 문제 동작 추가 개선 → 행동 차원 축소**의 흐름에서 최종 성능 상승은 마지막 단계에서 가장 뚜렷했다. 원본의 회전 제한을 생성 데이터와 모델 출력에 일관되게 반영하는 전략이 이 평가에서 유효할 가능성을 지지한다.

다만 이 단계는 Mimic 생성의 회전 제약과 정책 출력 7→5를 함께 적용했다. 따라서 관찰한 상승은 **행동 차원 축소를 일관되게 적용한 전체 전략의 결과**이며, 출력 헤드만 줄인 독립 효과를 분리해 확인한 것은 아니다. 평가 시드 42와 학습 시드 2개에서의 결과라는 범위도 유지한다.

결론과 지표의 해석 범위

질문	관찰한 결과	해석
품질을 고려한 첫 20개는?	20개 원본·500개 Mimic에서 39%·42%, 평균 40.5%	품질 중심 수집 전략을 적용한 첫 측정. 이 성공률만으로 원본 품질을 판단하지 않음
같은 전략에서 양을 늘리면?	평균 40.5→58.0%	같은 회전 제한을 유지하며 원본·성공 Mimic 수가 함께 늘어난 조건에서 상승
원본 동작을 개선하면?	접근 경로·상자 이동 감소, 평균 58.0→55.5%, SD5.0→2.5%p	원본 품질 지표의 개선과 정책 평균의 개선은 같지 않았음
출력 차원을 줄이면?	같은 100개에서 72%·70%, 평균 71.0%	생성 제약과 5D 출력을 함께 적용한 전략에서 상승

처음 20개부터 회전 제한을 통해 데이터의 품질과 구성을 관리하려 했다. 이후에는 **이 수집 전략을 유지하며 양을 확대하고, 발견된 문제 동작을 추가 개선**했다. 마지막에는 원본의 의도가 증강 데이터와 학습 action에 보존되는지까지 확인하면서 평균 71%를 얻었다. 초기 20개는 이 일련의 품질 중심 실험의 출발점이다.

지표	계산·정의	주의할 점
평가 성공률	성공한 rollout 수 /100	환경의 기존 성공 판정 사용
시드 간 표준편차	101·111 성공률의 SD,ddof=0	n=2, 신뢰구간이나 전체 시드 모집단의 안정성은 아님
파지 전 경로	최초 자동 grasp index까지 손끝 위치 간 거리의 합	20 Hz 실행 전 관측, 자동 신호의 경계 정의에 의존
방향 반전	x·y·z 명령의 비영 부호 전환 수 합	|명령|≤0.01 제외, 실제 속도 반전이나 실수 횟수와 다름
상자 이동	초기 상태 대비 실행 후 상자 중심의 최대 XY 변위	이동량은 접촉의 대리지표이며 힘·충돌 종류를 확정하지 않음
명령 비영률	|action|>10^{-6}인 step 비율	작은 노이즈도 포함, 물리적 회전의 크기를 나타내지 않음

품질 단계에는 9개 교체뿐 아니라 새 배치 3개 보충도 포함된다. 또한 원본에서 같은 action을 유지한 88개를 확인했지만, 자동 grasp 신호와 이후 생성 성공 자료의 구성은 비교에 영향을 줄 수 있다. 이런 변화와 두 시드의 표본 변동을 고려해, 개별 시범 하나의 성능 기여를 이번 결과만으로 확정하지 않는다.

회전 제한을 하지 않은 동일 조건의 대조 실험은 없어 초기 수집 전략 자체의 독립 효과는 분리하지 못했다. 다음 검증은 같은 회전 제약 Mimic 데이터에서 7D·5D 출력을 비교하는 것이다. 이번 보고서 개정에서는 새 수집·학습·평가를 실행하지 않았다.

부록 · 재수집 9개 상세 수치와 재현 근거

수집번호	파지 전 경로(m)	방향 반전(회)	파지 전 시간(s)	상자 이동(cm)
11	1.60 →1.35	6 →3	8.25 →8.85	0.14 →0.15
24	1.61 →1.10	7 →6	9.80 →6.80	6.15 →0.14
52	1.61 →1.54	6 →10	10.85 →11.25	0.15 →0.14
65	1.27 →1.69	1 →2	6.60 →9.50	2.78 →0.15
66	1.96 →1.12	11 →4	13.05 →5.85	0.15 →0.14
75	2.01 →1.54	11 →4	14.65 →10.80	0.14 →0.15
85	2.95 →1.45	22 →6	20.35 →9.10	0.14 →0.15
89	2.50 →1.36	13 →5	16.40 →8.55	0.26 →0.14
90	1.51 →1.49	5 →8	10.00 →9.25	0.15 →0.81

화살표는 같은 초기 배치의 재수집 전 → 후다. 수치가 작아졌는지만으로 절대적인 시범 품질을 판정하지 않는다. 예를 들어 65번은 상자 이동이 줄면서 경로와 시간이 늘었다. 초기 물체·로봇 pose의 최대 차이는 9쌍 모두 10^{-5} 이내였고, 기존 감사와 같은 지표 정의로 97개를 재계산해 일치를 확인했다.

공통 학습 조건: BC-RNN, LSTM 400×2층, GMM 5모드, sequence 10, batch 100. Epoch당 100 update로 총 2,000 epoch를 학습했다. 관측 23개를 유지하고 최종 epoch 2,000 모델을 선택했다. 모델당 100회, 평가 seed 42, horizon 800으로 비교했다.

근거·산출물	열기
강의 자료: 데이터 품질·구성·행동 표현	Week 08 ·51쪽 · 모방학습 실습 참고
네 단계 공식 결과	A · B · C · D
97개 시범의 이전 감사	원본 근거
재수집 계획·초기 배치 검증	원본 근거
손가락 끝 접촉의 기존 분석	원본 근거
차원 축소 구현·검증	원본 근거
로봇 기준 회전 명령 구현	원본 근거
두 원본 집합의 재계산 지표(97+100행)	source_quality.csv
동일 배치 9쌍의 전후 수치	paired_retake_quality.csv
네 단계 수치·정의·체크섬	revision_metrics.json

수치 계산·그림·HTML 제작 코드는 보고서와 같은 폴더에 보존한다.